

Trabajo Final de Aprendizaje Automático

Universidad de Cuenca

Jaime Paúl Arévalo Armijos, Esteban Darío Vizhñay Enderica

04-09-2024

Abstract

Introducción (0.5 páginas): contexto, necesidad (por que el problema es relevante), tarea (que es lo que se hizo para solucionar el problema e indicar claramente las entradas y salidas del problema), objetivo (objetivo general del proyecto).

Introducción

Las encuestas o cuestionarios de evaluación son uno de los métodos más utilizados para medir el desempeño de la planta docente de un instituto de educación. Esto permite a los docentes conocer cómo sus estudiantes perciben sus métodos de enseñanza y al mismo tiempo a la institución conocer la pedagogía de cada docente. El instituto a partir de los resultados podría considerar acciones correctivas, llamadas de atención, compensaciones, capacitaciones para mejorar la enseñanza de la planta docente, de igual manera los docentes pueden conocer como son identificados y caracterizados permitiendo trabajar en ellos mismos para mejorar o cambiar su pedagogía. Las encuestas, particularmente, pueden ser imparciales o sesgadas, debido a que cada estudiante es libre de elegir cómo calificar a sus docentes. Los resultados de la encuesta utilizada en este trabajo serán analizados de manera detallada, no solo con base en los resultados, sino también mediante un análisis exploratorio de datos y la aplicación de un modelo de clusterización. Nuestro objetivo es encontrar la percepción que tienen los estudiantes de sus docentes mediante un análisis del dominio del problema.

Trabajos relacionados (0.5 páginas): una revisión breve de trabajos similares.

Trabajos relacionados

Como lo afirma (Winer, DiGenova, Costopoulos, & Cardoso, 2016) las encuestas de evaluación son imparciales y confiables, aunque esto puede ser debatible y generar polémica en cuanto a la validez de las respuestas estudiantiles. Sin embargo (Groen & Herry, 2017) mencionan que las encuestas brindan resultados sesgados y pocos precisos, esto se puede apoyar al comportamiento descrito por (Maurer, 2006) que indica que los estudiantes con buenas notas califican al docente de manera positiva y manera negativa si poseen malas notas. De igual manera (Zumbach & Funke, 2014) indica que el estado de ánimo es un factor importante en las respuestas de las encuestas aplicadas. El análisis exploratorio de datos (ADA) como lo indica (Dhar, 2013) permite a los líderes educativos analizar más a fondo sus datos, en lugar de centrarse simplemente en interpretar resultados, el uso de ADA y otras técnicas de ciencia de datos combinan en una amplia gama de conjuntos de habilidades (análisis básico, estadísticas, modelos de aprendizaje e inteligencia artificial) permitiendo predecir el impacto futuro de una decisión con base en sus datos. Lo más importante para el uso eficaz de ADA es el conocimiento subyacente del profesional que da significado a los resultados e impulsa la necesidad de cambio necesario. (Bill & Melinda Gates Foundation, 2015; Dhar, 2013; Tichnor-Wagner, Wachen, Cannata y Cohen-Vogel, 2017)

Descripción del dataset

El conjunto de datos utilizado en este trabajo esta compuesto por 33 columnas, las cuales son descritas en la siguiente tabla:

Nombre	Descripción	Tipo
instr	Identificador del docente	Númerico
class	Código del curso	Númerico
repeat	Número de veces que el estudiante tomo el curso	Númerico
attendance	Código del nivel de asistencia	Númerico
difficulty	Nivel de dificultad del curso percibida por el estudiante	Númerico
Q1	El contenido del curso semestral, el método de enseñanza y el sistema de evaluación se proporcionaron desde el inicio.	Númerico
Q2	Los objetivos del curso se establecieron claramente desde el inicio del período.	Númerico
Q3	El curso valió la cantidad de créditos que se le asignaron.	Númerico
Q4	El curso se impartió de acuerdo con el programa anunciado el primer día de clase.	Númerico
Q5	Los debates en clase, las tareas, las aplicaciones y los estudios fueron satisfactorios.	Númerico
Q6	El libro de texto y otros recursos del curso fueron suficientes y actualizados.	Númerico
Q7	El curso permitió trabajo de campo, aplicaciones, laboratorio, debate y otros estudios.	Númerico
Q8	Los cuestionarios, las tareas, los proyectos y los exámenes contribuyeron a facilitar el aprendizaje.	Númerico
Q9	Disfruté mucho de la clase y estaba ansioso por participar activamente durante las conferencias.	Númerico
Q10	Mis expectativas iniciales sobre el curso se cumplieron al final del período o año.	Númerico
Q11	El curso fue relevante y beneficioso para mi desarrollo profesional.	Númerico
Q12	El curso me ayudó a ver la vida y el mundo con una nueva perspectiva.	Númerico
Q13	El conocimiento del instructor era relevante y actualizado.	Númerico
Q14	El instructor llegó preparado para las clases.	Númerico
Q15	El instructor enseñó de acuerdo con el plan de lecciones anunciado.	Númerico
Q16	El instructor se comprometió con el curso y fue comprensible.	Númerico
Q17	El instructor llegó a tiempo a las clases.	Númerico
Q18	El instructor tiene una presentación/discurso fluido y fácil de seguir.	Númerico
Q19	El instructor hizo un uso eficaz de las horas de clase.	Númerico
Q20	El instructor explicó el curso y estaba ansioso por ayudar a los estudiantes.	Númerico
Q21	El instructor demostró un enfoque positivo hacia los estudiantes.	Númerico
Q22	El instructor fue abierto y respetuoso con las opiniones de los estudiantes sobre el curso.	Númerico
Q23	El instructor alentó la participación en el curso.	Númerico
Q24	El instructor asignó tareas/proyectos relevantes y ayudó/guió a los estudiantes.	Númerico
Q25	El instructor respondió preguntas sobre el curso dentro y fuera del curso.	Númerico
Q26	El sistema de evaluación del instructor (preguntas de mitad de curso y finales, proyectos, tareas, etc.) midió eficazmente los objetivos del curso.	Númerico
Q27	El instructor proporcionó soluciones a los exámenes y las discutió con los estudiantes.	Númerico
Q28	El instructor trató a todos los estudiantes de manera correcta y objetiva.	Númerico

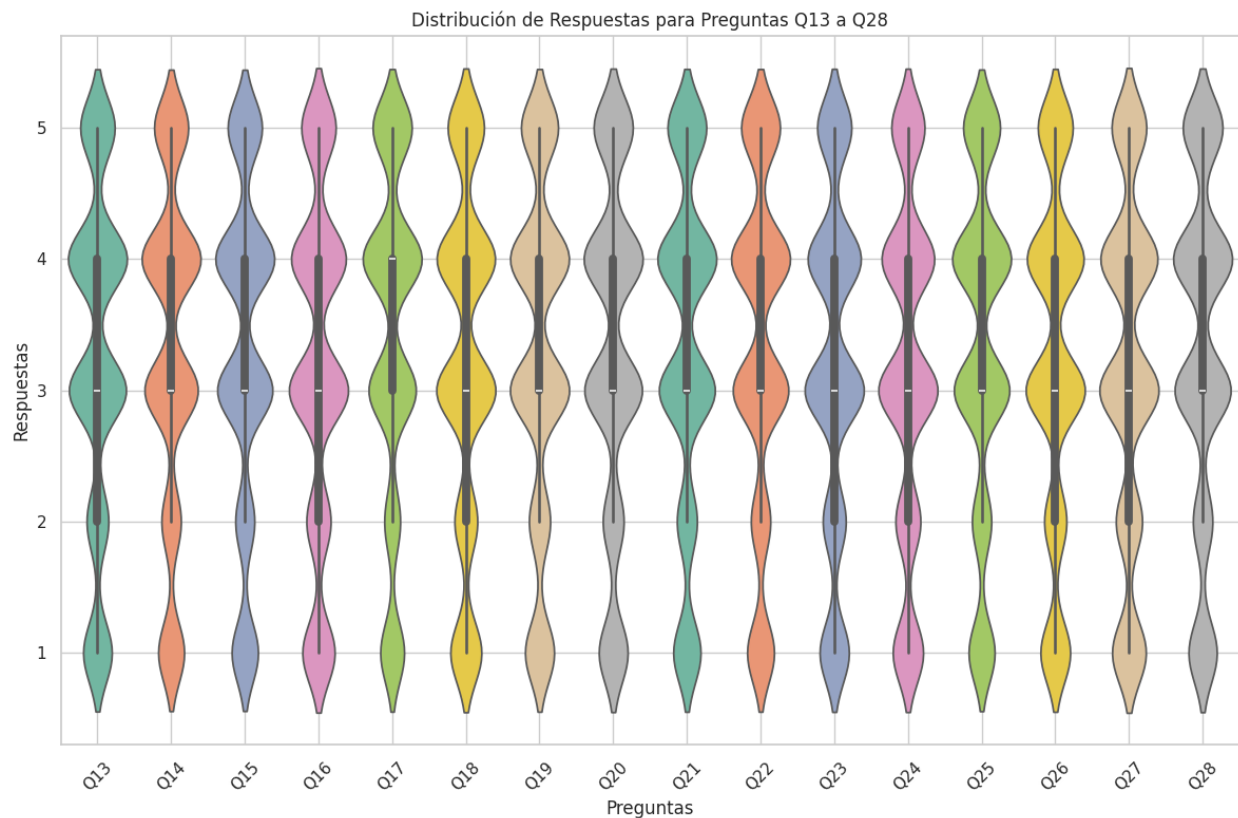
A partir de las columnas anteriores, se han seleccionado las siguientes columnas que van en dirección al objetivo de este trabajo: **instr**, **Q13-Q28**. La primera columna servirá como etiqueta de nuestro modelo de clusterización. Las preguntas desde la 13 hasta la 28 se centran en aspectos clave de la enseñanza del docente como conocimiento, preparación, comprensión, fluidez de enseñanza, participación, forma de evaluar a los estudiantes. No se realizó ningún tipo de preprocesamiento o transformación a los datos, ya que estos se encuentran limpios y sin valores ausentes, además las preguntas toman valores desde el 1 al 5. Donde se asignó 1 = Nunca, 2 = Casi nunca, 3 = A veces, 4 = Casi siempre, 5 = Siempre.

Metodología

Para el pre-procesamiento del conjunto de datos a analizar, es importante notar que ninguna de las variables presenta datos faltantes o ausentes. Esto es un aspecto positivo que simplifica el análisis, ya que no es necesario realizar imputaciones ni eliminar registros incompletos. No obstante, dado que las variables se encuentran en una escala Likert, los datos de estudio son ordinales. Este tipo de datos no solo implica que los valores tienen un orden específico, sino que también es crucial identificar que las diferencias entre los puntos de la escala no son necesariamente equidistantes. Esto sugiere que, aunque las respuestas estén estandarizadas en términos de escala, su naturaleza ordinal requiere un manejo cuidadoso en el modelado, asegurando que las técnicas utilizadas respeten la estructura inherente de los datos. Además, al trabajar con modelos de aprendizaje no supervisado, es fundamental considerar la normalización o estandarización adecuada para mejorar la eficacia de los algoritmos aplicados, ya que el rango limitado y la escala uniforme pueden influir en los resultados de clustering o reducción de dimensionalidad, entre otros enfoques.

La gráfica del método del codo muestra un descenso pronunciado en la suma de cuadrados dentro del cluster a medida que aumenta el número de clusters. El punto donde la disminución deja de ser tan pronunciada indica el número óptimo de clusters, en el caso del conjunto de datos seleccionado, la gráfica recomienda que los valores para el número de clusters puede ser 3 o 4. Así que se considera tales valores para el análisis para de esta manera identificar y evaluar cual produce los clusters más significativos y útiles para aplicarlo sobre los datos.

En el análisis exploratorio de datos, procedimos a examinar las distribuciones de las variables relevantes y realizar una comparación conjunta de las mismas, con el objetivo de extraer conclusiones preliminares alineadas con el propósito de evaluación intrínseco de cada pregunta. Para visualizar las distribuciones de las respuestas, se utilizó un gráfico de violín que permite comparar directamente la distribución de respuestas entre las diferentes preguntas. Esta herramienta gráfica facilita la identificación de patrones, tendencias y posibles áreas de interés o mejora al observar cómo varían las percepciones de los estudiantes en relación con cada aspecto evaluado.



Este gráfico elimina la necesidad de un análisis descriptivo exhaustivo, ya que las medias se sitúan en un rango estrecho de aproximadamente 3.1 a 3.4, con una varianza cercana a 1.2. Estos patrones se reflejan claramente en el gráfico de violín, donde se observa una mayor densidad de respuestas en los valores 3 y 4 para cada pregunta.

La simetría de las distribuciones indica que las respuestas están distribuidas de manera uniforme alrededor de la mediana, lo que sugiere que los estudiantes tienen una opinión equilibrada sobre los aspectos del curso y los instructores. Esto sugiere una satisfacción general con los docentes. Es importante destacar que en preguntas como la 13, 14, 17 y 28 se observa una ligera concentración de respuestas entre los valores 4 y 5, lo que podría indicar que los estudiantes valoran positivamente el conocimiento del instructor, su preparación, puntualidad y trato justo. Estos aspectos reflejan un alto nivel de compromiso por parte de los docentes.

Por otro lado, preguntas como la 16, 18 y 19 muestran una mayor dispersión en las respuestas, lo que indica un cierto grado de variabilidad en la percepción de los estudiantes sobre la claridad en la exposición de los temas del curso y la capacidad del instructor para ser comprendido. Esta variabilidad sugiere que estas preguntas están más sujetas a interpretaciones personales o a diferencias en las expectativas de los estudiantes respecto a los profesores y los cursos. La pregunta 19, que evalúa el uso efectivo del tiempo en clase, aunque subjetiva, también puede señalar un área donde los estudiantes perciben un posible margen de mejora.

Resultados y Discusión


Se determinó el número recomendado de clústeres en los que se podría dividir el conjunto de datos utilizando el Silhouette Score y el Davies-Bouldin Score, obteniendo resultados que sugerían entre 8 y 9 clústeres. Sin embargo, identificar características significativas y con alto grado de interpretación en un número tan elevado de clústeres se complicaría, y no proporcionaría una recomendación clara para el análisis del problema. Se aplicaron algoritmos de reducción de dimensionalidad como PCA y t-SNE. Este último mostró una mayor separación entre los clústeres, especialmente al ajustar hiperparámetros como el **perplexity**, lo que permitió observar divisiones claras en tres o cuatro clústeres, dependiendo del valor del hiperparámetro.

Se aplicaron varios modelos de clustering a los datos utilizando los componentes obtenidos en los pasos anteriores. Los modelos utilizados fueron K-Means, DBSCAN, BIRCH, Propagación de Afinidad y Clustering Jerárquico con el método de Ward, apoyado por un dendrograma. La reducción de dimensionalidad con PCA y t-SNE mostró que al usar dos componentes con alta representatividad (según la gráfica de varianza acumulada), los grupos aparecían muy juntos y correlacionados, lo que dificultaba distinguir los clústeres en la representación gráfica en dos dimensiones. En la siguiente gráfica se muestran los clusters obtenidos utilizando el algoritmo de K-Means.



Por esta razón, K-Means se destacó como el algoritmo más adecuado para identificar clústeres, aunque BIRCH y el método de Ward también produjeron resultados similares. K-Means fue particularmente eficiente, ya que no se observaron patrones irregulares en la representación en dos dimensiones, y su enfoque basado en centroides se ajustó bien a las características de los datos.

Finalmente se realizó un análisis comparativo sobre la columna clasificadora que era la del instructor o docente para identificar si existen algunos factores representativos sobre los clusters pero sin embargo no se obtuvieron analisis relevantes sobre los gráficos y resultados de las tablas comparativas. Entonces se procedió a generar un análisis distinto en donde de forma gráfica procedemos a generar una visualización de cada una de las preguntas, donde por en cada grafico contenga el conteo de las respuestas por cada opción elegida del uno al cinco y segmentado por el tipo de cluster. Obtuvimos un mejor panorama visual para establecer resultados que permitan generar interpretaciones con un respaldo ciertamente significativo. En la siguiente gráfica se muestra el número de respuestas obtenidas, organizadas por clúster y desglosadas por cada uno de los valores asignados a las preguntas finales analizadas (Q25 a Q28).



Tal y como se refleja en la gráfica, existen tres grupos distintos de percepciones estudiantiles sobre la calidad de la enseñanza. El clúster 0 agrupa a estudiantes que califican la experiencia de manera moderada, con respuestas mayormente en los valores 3 y 4, lo que sugiere una satisfacción general pero tal vez con reconocimiento de áreas para mejora. El clúster 1 representa a los estudiantes más insatisfechos, quienes seleccionaron principalmente los valores 1 y 2, lo que indica percepciones negativas sobre múltiples aspectos del curso, materia dictada o hacia los profesores. Por último, el clúster 2 incluye a los estudiantes más satisfechos, con un índice alto de respuestas en el valor 5, reflejando una alta satisfacción con la enseñanza o tal vez una falta de interés hacia la evaluación del docente debido a un apego hacia el curso o materia impartida por el profesor.

En el análisis general, se observa que los estudiantes en el clúster 2 muestran una satisfacción consistente en todos los aspectos evaluados, destacándose en preguntas relacionadas con la preparación del instructor, la claridad en la enseñanza y la evaluación del curso. Por otro lado, el clúster 1 revela preocupaciones específicas en áreas como la claridad del discurso y la eficacia del tiempo de clase, donde se perciben más deficiencias. El clúster 0 sugiere una percepción positiva pero no sobresaliente, con un enfoque en la mejora continua. Estos patrones permiten identificar no solo las áreas de éxito, sino también aquellas que requieren atención para elevar la satisfacción general de los estudiantes.

Conclusión

El análisis de las respuestas agrupadas por clústeres ha revelado patrones claros en la percepción de los estudiantes sobre la calidad de la enseñanza. Los clústeres identificados muestran una variabilidad significativa en la satisfacción estudiantil: el clúster 0 representa a estudiantes moderadamente satisfechos, el clúster 1 agrupa a aquellos con una opinión negativa y el clúster 2 agrupa a los estudiantes muy satisfechos. Esto sugiere que, aunque una la mayor parte de estudiantes tienen una percepción positiva sobre la enseñanza, existe una fracción significativa que identifica áreas de mejora importantes, particularmente en la claridad del discurso, el uso efectivo del tiempo en clase, y la estructura de las asignaciones y evaluaciones.

El uso de técnicas de clústering permitió segmentar a los estudiantes en grupos homogéneos según sus respuestas. Esto proporcionó una visión más precisa de cómo diferentes aspectos de la enseñanza son percibidos. La interpretación de los clústeres, en conjunto con el análisis visual de las distribuciones de

respuestas, permitió identificar patrones relevantes que de otro modo podrían haber quedado ocultos en un análisis descriptivo de los datos.

En cuanto al trabajo futuro, sería valioso realizar un análisis más profundo, integrando otras variables demográficas o contextuales que puedan influir en la percepción de los estudiantes. También se podría explorar el uso de modelos predictivos, como la regresión logística, para identificar qué factores específicos están más fuertemente asociados con la pertenencia a cada clúster, lo que podría guiar mejoras específicas en la enseñanza. Además, un seguimiento a través del tiempo podría ayudar a evaluar cómo las intervenciones basadas en este análisis afectan la satisfacción estudiantil en el tiempo.

Contribuciones

En el presente trabajo, ambos integrantes participaron activamente en todas las etapas del proyecto. Colaboramos en la generación del código para el análisis, realizamos juntos la visualización de los resultados en una computadora y redactamos varios párrafos de cada sección del informe. Debido a nuestra participación conjunta en todas las fases del proceso, la contribución de cada uno sobre el trabajo fue equitativa.

Referencias

- Winer, L., DiGenova, L., Costopoulos, A., & Cardoso, K. (2016). Addressing common concerns about online student ratings of instruction: A research-informed approach. *Canadian Journal of Higher Education/Revue canadienne d'enseignement supérieur*, 46(4), 115–131.
- Groen, J. F., & Herry, Y. (2017). The online evaluation of courses: Impact on participation rates and evaluation scores. *Canadian Journal of Higher Education/Revue canadienne d'enseignement supérieur*, 47(2), 106–120.
- Maurer, T. W. (2006). Cognitive dissonance or revenge? Student grades and course evaluations. *Teaching of Psychology*, 33, 176–179.
- Zumbach, J., & Funke, J. (2014). Influences of Mood on Academic Course Evaluations. *Practical Assessment, Research & Evaluation*, 19(4), 1–12. Retrieved from <http://pareonline.net/getvn/getvn.asp?v=19&n=4>.
- Dhar, V. (2013). Data science and prediction. *Communications of the ACM*, 56(12), 64–73. doi:10.1145/2500499
- Bill & Melinda Gates Foundation. (2015). Making data work for teachers and students. Seattle, WA: Bill & Melinda Gates Foundation.
- Tichnor-Wagner, A., Wachen, J., Cannata, M., & Cohen-Vogel, L. (2017). Continuous improvement in the public school context: Understanding how educators respond to plan-do-act cycles. *Journal of Education Change*, 18(4), 465–494. doi:10.1007/s10833-017-9301-4.